FDA 2주차 실습 과제 강의노트

Oct 3, 2026 · @수린

과제 개요

이 노트북은 금융데이터분석 2주차 과제로, KOSPI200 데이터를 내려받아 검증·탐색하는 **Lab 1 본문**과 학생이 직접 자료를 찾아 푸는 **Assignment 2개**로 이루어져 있다. 전체를 관통하는 질문은 "우리가 분석하려는 이 금융데이터는 정확히 무엇인가?"이다.

Lab 본문은 이미 완성된 코드라 실행하면서 이해하면 된다. 실제로 작성해야 하는 것은 Assignment 1·2의 코드 셀과 해석, 그리고 데이터 출처 표다.

부분	노트북 위치	내용	학생이 할 일
Lab 1 본문	§1–§19	구성종목 CSV 읽기, 지수·개별주가 다운로드, 패널 검증, 수익률 계산, EDA, 저장	실행하고 이해하기
Assignment 1	본문 다음	현재 KOSPI200의 산업구조 분석	산업분류 자료를 찾아 결합, 표·그래프·해석 작성
Assignment 2	Assignment 1 다음	전체 기간 구성종목 변화와 survivorship bias	시점별 편입·편출·turnover 계산, 표·그래프·해석 작성
데이터 출처 기록	끝부분	사용한 데이터의 출처 표 4행	출처·기준일 채우기 (채점에서 중요하게 봄)
제출	마지막	Restart Kernel → Run All 후 노트북과 data 폴더를 ZIP으로	파일명 규칙 지키기

Lab 본문은 Yahoo Finance(개별 종목)와 FinanceDataReader(KOSPI200 지수)를 쓰며, pykrx는 불안정해서 일부러 쓰지 않는다.

학습 목표

과제를 마치면 "데이터를 받았다"에서 멈추지 않고 "이 데이터가 무엇을, 언제부터, 어떤 기준으로 담고 있는가"를 설명할 수 있어야 한다. 노트북이 내세우는 7가지 학습 내용은 다음과 같다.

1. KOSPI200 구성종목 universe를 정의한다.
2. observation grain, 즉 데이터 한 행이 무엇을 뜻하는지 정한다 (날짜 × 종목).
3. data availability와 unbalanced panel을 이해한다.
4. OHLCV와 수정주가(adjusted price)를 구분한다.

5. 단순수익률과 로그수익률을 계산하고 차이를 안다.
6. KOSPI200 지수와 개별 종목 EDA를 한다 (6개 시계열 비교 포함).
7. 산업구조, 구성종목 변화, survivorship bias를 분석한다.

또 하나의 목표는 **자료를 스스로 찾고 근거를 남기는 습관**이다. Assignment에서는 산업분류와 과거 구성종목 이력을 직접 구해 출처를 기록해야 한다.

각 절은 개념 → 수식 → 코드 → 출력 → 해석 → 실패 사례(failure mode) 순서로 짜여 있으니, 읽을 때도 이 흐름을 따라가면 된다.

배경 개념

두 Assignment는 모두 Lab 본문의 개념 위에 서 있다. 아래 일곱 가지를 먼저 이해하고 과제에 들어가자.

1. Universe와 관측 단위

Universe는 분석 대상 종목의 집합이다. 이 Lab에서는 2025-12-30 기준 KOSPI200 구성종목 200개(`kospi200_20251230.csv`)이고, 종목코드에 `.KS`를 붙여 Yahoo ticker로 바꾼다.

가격 패널의 한 행은 **날짜 × 종목**이다. 그래서 (Date, Symbol) 중복이 0개인지, High < Low나 음수 거래량이 없는지 검증한다.

2. Unbalanced panel

종목마다 상장일이 달라 데이터 시작일도 다르다. 실행 결과 삼성전자는 2000-01-04부터, LG씨엔에스는 2025-02-05부터 데이터가 있다. 이는 오류가 아니라 실제 시장을 그대로 반영한 구조다.

다운로드는 199개 성공, 1개(`000126.KS`) 실패였다. 실패한 종목을 다른 ticker로 추측해 대체하지 않고 실패로 기록하는 것이 이 Lab의 원칙이다.

3. 결측(NaN)은 한 종류가 아니다

결측 원인	의미	처리 원칙
상장 전	기업이 아직 시장에 없음	채우면 안 됨 (구조적 결측)
거래정지	기업은 있지만 거래가 없음	원인을 확인한 뒤 판단
휴장일	애초에 관측 대상이 아님	행 자체가 없어야 정상

원인을 구분하지 않고 `df.ffill()`로 채우면 서로 다른 경제적 상태가 섞인다.

4. 수정주가와 수익률

수익률은 배당·액면분할 등을 반영한 수정주가(AdjClose)로 계산한다. 단순수익률과 로그수익률은 다음과 같다.

```
R_{i,t} = \frac{AdjClose_{i,t}}{AdjClose_{i,t-1}} - 1
```

```
r_{i,t} = \ln(AdjClose_{i,t}) - \ln(AdjClose_{i,t-1})
```

여러 기간을 합칠 때 로그수익률은 더하고, 단순수익률은 (1 + R)을 곱한다. 또 계산은 반드시 `groupby("Symbol")` 뒤에 해야 한다. 그러지 않으면 앞 종목의 마지막 날과 다음 종목의 첫날 사이에 가짜 수익률이 생긴다.

5. 극단 수익률은 조사 대상

일별 수익률 절댓값이 0.35를 넘는 관측치가 138건 나왔다. 한국 주식의 가격제한폭은 ±30%이므로 정상 거래로는 나올 수 없는 값이고, 액면분할·기업분할·권리락이나 데이터 업체의 수정주가 오류를 의심해야 한다.

예를 들어 SK하이닉스의 최저 일수익률이 -190%로 나온다. 수익률은 -100% 아래로 내려갈 수 없으므로 명백한 데이터 이상이다. 이런 값은 삭제하거나 winsorize하지 않고, 기록하고 해석에서 언급한다.

6. 개별 EDA와 비교 EDA의 기간

개별 종목 요약 통계는 각 종목의 전체 history를 쓴다. 반면 6개 시계열의 상관관계와 정규화 가격 비교는 **공통으로 겹치는 날짜**(실행 결과 3,933일)만 쓴다. 두 방식을 섞으면 안 된다.

요약표의 MeanToStd는 평균을 표준편차로 나눈 값일 뿐, 무위험이자율 차감이나 연율화를 하지 않았으므로 Sharpe ratio가 아니다.

7. Survivorship bias

지수 구성종목은 시간에 따라 바뀐다. 현재 구성종목만으로 과거를 분석하면 그사이 지수에서 빠진 기업, 즉 부진했거나 상장폐지된 기업이 체계적으로 빠진다. 그 결과 과거 성과가 실제보다 좋아 보인다.

`period="max"`로 가격 history를 길게 받는 것과 각 시점의 구성종목(point-in-time universe)이 정확한 것은 서로 다른 문제다. 이것이 Assignment 2의 핵심이다.

문제별 해설

Assignment 1 — KOSPI200 구성종목과 산업구조

요구사항: 현재 200개 구성종목에 산업분류를 붙여 산업별 종목 수, 구성비, 평균수익률, 변동성을 구하고 표, 그래프 1개 이상, 3~5문장 해석을 작성한다.

산업 j의 구성비와 일별 동일가중 수익률은 다음과 같다.

```
Share_{j,t} = \frac{N_{j,t}}{N_t}
```

```
R_{j,t} = \frac{1}{N_{j,t}} \sum_{i \in j} R_{i,t}
```

풀이 순서:

1. **산업분류 자료 찾기.** 거래소 업종, KSIC(한국표준산업분류), GICS/WICS 등 신뢰할 수 있는 분류를 골라 종목코드–산업 표로 정리한다. 어떤 분류를 썼는지 출처 표에 반드시 적는다.
2. **universe에 결합.** `Symbol` 기준 left merge 후, 산업이 비어 있는 종목이 몇 개인지 확인한다.
3. **prices에도 다시 결합.** `prices`의 `Industry` 열은 Lab에서 비어 있는 상태로 합쳐졌으므로, 새 산업분류로 갈아 끼워야 §17-F 코드가 SKIP되지 않는다.
4. **종목 수·구성비 표.** `value_counts()`로 종목 수를 세고 전체로 나눈다.
5. **평균수익률·변동성 표.** §17-F의 helper 코드를 그대로 재사용한다. 날짜 × 산업으로 일별 평균수익률을 만든 뒤 산업별 평균과 표준편차를 구한다.
6. **그래프.** 산업별 종목 수 막대그래프, 또는 평균수익률–변동성 산점도가 무난하다.
7. **해석 3~5문장.** 어느 산업 비중이 큰지, 위험과 수익이 높은 산업은 어디인지, 결과를 왜곡할 수 있는 요인은 무엇인지 쓴다.

결합 부분 예시 코드:

```
my_industry = pd.read_csv(Path("data/FDA_kospi200_industry.csv"), dtype=
{"Symbol": str})
my_industry["Symbol"] = my_industry["Symbol"].str.zfill(6)

# Lab에서 만든 빈 산업 컬럼을 지워야 Industry_x / Industry_y가 생기지 않는다
universe = universe.drop(columns=["IndustryCode",
"Industry"]).merge(my_industry, on="Symbol", how="left")
print("산업 미결합 종목 수:", universe["Industry"].isna().sum())

prices = prices.drop(columns=["IndustryCode", "Industry"]).merge(
    universe[["Symbol", "Industry"]], on="Symbol", how="left"
)

ind_count = universe["Industry"].value_counts().rename("N").to_frame()
ind_count["Share"] = ind_count["N"] / ind_count["N"].sum()
```

해석할 때 짚을 점: 종목마다 데이터 시작일이 달라 산업 내 종목 수(NStocks)가 시기마다 변한다. 또 극단 수익률(예: 하이트진로 +1,310%)이 그대로 남아 있으면 그 종목이 속한 산업의 평균과 변동성이 크게 부풀려진다. 분석 기간과 이런 한계를 해석에 명시하면 좋다.

Assignment 2 — 구성종목 변화와 Survivorship Bias

요구사항: 과거 구성종목 자료가 있는 **전체 기간**에 대해 연속된 모든 시점 쌍의 편입·편출·잔류와 turnover를 계산한다. 두 시점만 골라 한 번 비교하면 미완성으로 본다.

$$Stayed_t = C_t \cap C_{t-1}, \quad Added_t = C_t - C_{t-1}, \quad Deleted_t = C_{t-1} - C_t$$

$$Turnover_t = \frac{|Added_t| + |Deleted_t|}{2|C_{t-1}|}$$

$$SurvivalRate_{1,T} = \frac{|C_1 \cap C_T|}{|C_1|}, \qquad N^{ever} = \left| \bigcup_{t=1}^{T} C_t \right|$$

제출해야 하는 결과물:

결과물	내용
Table 1	시점별 변화표: Date, N_Constituents, N_Stayed, N_Added, N_Deleted, Turnover
Table 2	전체 기간 누적 편입·편출 종목의 산업분포
Graph	Turnover 시계열 또는 Added/Deleted 시계열
Summary	FirstDate, LastDate, N_Snapshots, N_Ever_Members, LongRun_SurvivalRate
Interpretation	3~5문장 survivorship bias 해석

데이터: 노트북 §5에 따르면 `FDA_week02_lab_assignment_dataset/` 폴더에 2006-08-31부터 2025-12-30까지 반기별 snapshot 40개(`kospi200_YYYYMMDD.csv`)가 들어 있다. 파일 안에는 날짜 열이 없으므로 **파일명에서 기준일을 꺼내야** 한다.

전체 기간 반복 예시 코드:

```
snap_files = sorted(CONSTITUENT_DIR.glob("kospi200_*.csv"))
frames = []
for f in snap_files:
    df = read_csv_robust(f)
    df["AsOfDate"] = pd.to_datetime(f.stem.split("_")[1], format="%Y%m%d")
    frames.append(df)
history = pd.concat(frames, ignore_index=True)
history["Symbol"] = history["종목코드"].astype(str).str.zfill(6)

dates = sorted(history["AsOfDate"].unique())
C = {d: set(history.loc[history["AsOfDate"] == d, "Symbol"]) for d in dates}
```

```
records = []
for prev, curr in zip(dates[:-1], dates[1:]):
    res = compare_constituents(C[prev], C[curr])
    records.append({
        "Date": curr,
        "N_Constituents": len(C[curr]),
        "N_Stayed": len(res["Stayed"]),
        "N_Added": len(res["Added"]),
        "N_Deleted": len(res["Deleted"]),
        # convention: 분모 = 2|C_{t-1}|
        "Turnover": (len(res["Added"]) + len(res["Deleted"])) / (2 *
len(C[prev])),
    })
table1 = pd.DataFrame(records)

n_ever = len(set().union(*C.values()))
longrun_survival = len(C[dates[0]] & C[dates[-1]]) / len(C[dates[0]])
```

Table 2가 가장 까다롭다. 편출된 종목 상당수는 현재 구성종목이 아니므로 Assignment 1의 산업분류에 없다. 과거 종목까지 포함된 산업분류를 따로 구하거나, 매칭되지 않은 종목 수를 "분류 불가"로 명시해야 한다.

해석에서 답할 질문(노트북 제시):

- Turnover가 시간에 따라 일정한가, 편입·편출이 몰린 시기는 언제인가?
- 어떤 산업에서 편입·편출이 많았는가?
- 최초 구성종목 중 마지막까지 남은 비율은 얼마인가?
- 한 번이라도 편입된 종목 수(N_ever)는 현재 200개와 얼마나 다른가?
- 현재 구성종목만으로 과거를 분석하면 어떤 기업이 빠지고, 그것이 과거 수익률이나 기술적 전략 평가를 어떻게 왜곡하는가?

자주 하는 실수와 제출 전 체크리스트

감점은 대부분 계산 실수보다 데이터 결합과 제출 형식에서 나온다.

실수	증상	해결
종목코드 앞자리 0 손실	`005930`이 `5930`이 되어 merge가 전부 실패	`dtype=str`로 읽고 `.str.zfill(6)`
빈 산업 컬럼을 지우지 않고 merge	`Industry_x`, `Industry_y`가 생김	merge 전에 `drop(columns=...)`

실수	증상	해결
prices에 산업을 다시 붙이지 않음	§17-F가 계속 SKIP 출력	universe와 prices 둘 다 갱신
groupby 없이 `pct_change()`	종목 경계에 가짜 수익률	`groupby("Symbol")` 뒤에 계산
`ffill()`로 결측 메우기	상장 전 구간에 가짜 가격	결측 원인을 먼저 구분
두 시점만 비교	Assignment 2 미완성 처리	모든 연속 시점 쌍을 반복
Turnover 분모 미명시	결과 해석 불가	코드 주석이나 해석에 convention 명시
절대경로 사용	채점자 PC에서 실행 실패	`data/...` 상대경로만 사용
그래프 한글 깨짐	맑은 고딕은 Windows 전용	Mac은 `AppleGothic`, Colab은 나눔폰트 설치

제출 전 체크리스트

- [ ] 학번과 이름을 파일명에 넣었다 (`FDA_week02_lab_assignment_학번_이름.ipynb`).
- [ ] Assignment 1 코드, 표, 그래프, 해석을 완료했다.
- [ ] Assignment 2 Table 1·2, 그래프, Summary, 해석을 완료했다.
- [ ] 데이터 출처 표 4행(구성종목, 산업분류, 주가, historical 구성종목)을 채웠다.
- [ ] Restart Kernel → Run All로 처음부터 오류 없이 돌아가는 것을 확인했다.
- [ ] 실행 결과와 그래프가 노트북에 저장되어 있다.
- [ ] 실제 사용한 데이터 파일을 `data/` 폴더에 넣었다.
- [ ] 전체 폴더를 `FDA_week02_학번_이름.zip` 하나로 압축했다.

교수자에게 확인할 점

노트북 안에 서로 맞지 않는 설명이 몇 군데 있어, 과제 전에 확인해 두는 것이 안전하다.

- **분석 기준일:** 설정 코드는 2025-12-30인데, §7·§8·§18과 핵심 정리에는 2026-08-31이 나온다. 코드는 2025-12-30으로 실행되므로 해석도 이 날짜 기준으로 쓰는 것이 자연스럽다.
- **구성종목 수:** CSV와 assert는 200개인데, §17-D와 핵심 정리에는 201개로 적혀 있다.
- **Assignment 2 데이터:** §5는 제공된 dataset 폴더의 snapshot 40개를 "Assignment 2에서 사용"한다고 하지만, Assignment 설명은 자료를 직접 찾으라고 한다. 제공 파일을 써도 되는지, 쓴다면 출처를 어떻게 적을지 확인하자.
- **제출 폴더 위치:** 제공 snapshot은 `data/`가 아니라 노트북 옆 dataset 폴더에 있다. 제출 규칙은 실제 사용한 데이터를 `data/`에 넣으라고 하므로, 복사해 넣고 경로를 맞추는 편이 안전하다.