Financial Machine Learning Projects 2
Hybrid Volatility Models

Financial AI Convergence Program, CAU Business School, Chung-Ang University

March 2026

1 프로젝트 개요

최근 금융계량 및 머신러닝 연구에서는 전통적인 변동성 모형(GARCH)과 딥러닝 모델을 결합한 **hybrid volatility model**이 활발히 연구되고 있다. 전통적 GARCH 모형은 금융시계열의 변동성 군집화(volatility clustering), persistence, leverage effect 등을 잘 설명하지만, 복잡한 비선형 패턴을 충분히 반영하지 못할 수 있다. 반면 딥러닝 모델은 복잡한 비선형성을 유연하게 학습할 수 있지만, 금융이론에 기반한 구조적 해석은 상대적으로 약할 수 있다.

이번 프로젝트의 목표는 다음 세 가지 접근을 실제 한국 금융데이터에 적용하여 비교하는 것이다.

- 전통적인 계량경제학 모형: GARCH, DCC-GARCH
- 딥러닝 모형: LSTM, GRU, Transformer 등
- 결합 모형: Hybrid GARCH + Deep Learning

학생들은 실제 데이터를 직접 수집하고, 수익률과 변동성을 계산하고, 모형을 추정한 뒤, 예측 성과를 비교하고 경제적 의미를 해석하게 된다.

2 사용 데이터

다음 5개 한국 금융자산의 일별 데이터를 사용한다.

- KOSPI Index
- Samsung Electronics
- SK Hynix
- Hyundai Motor
- NAVER

표본기간은 예를 들어 다음처럼 설정할 수 있다.

- 2015-01-01 $\sim$ 2025-12-31

가격 데이터는 Yahoo Finance, KRX, 또는 다른 공신력 있는 데이터 소스를 통해 수집할 수 있다. Python에서는 `yfinance` 패키지를 사용할 수 있다.

2.1 로그수익률 계산

금융시계열 분석에서는 보통 가격 자체보다 수익률을 사용한다. 본 프로젝트에서는 일별 로그수익률을 다음과 같이 정의한다.

$$r_t = 100 \times \log\left(\frac{P_t}{P_{t-1}}\right)$$

여기서

- P_t: 시점 t의 종가
- r_t: 시점 t의 일별 로그수익률

3 Project 1 (기초): Hybrid GARCH + Deep Learning Volatility Forecasting

3.1 프로젝트 목표

이 프로젝트의 목적은 단일 자산의 변동성을 예측할 때 다음 세 가지 접근을 비교하는 것이다.

- GARCH 기반 변동성 예측
- Deep Learning 기반 변동성 예측
- GARCH와 Deep Learning을 결합한 Hybrid 예측

학생들은 각 자산에 대해 GARCH 모형을 먼저 추정하고, 그 결과를 딥러닝 입력변수로 활용하여 hybrid model을 구성하게 된다.

3.2 왜 Hybrid Model을 사용하는가?

Hybrid model의 아이디어는 다음과 같다.

- GARCH는 금융시장의 조건부 이분산성(conditional heteroskedasticity)을 잘 설명한다.
- 딥러닝은 비선형성, 복잡한 시차 구조, 잠재 패턴을 유연하게 학습할 수 있다.
- 따라서 GARCH가 제공하는 구조적 정보와 딥러닝의 표현력을 함께 사용하면 예측력이 향상될 수 있다.

즉, GARCH는 "금융이론 기반 구조"를 제공하고, 딥러닝은 "데이터 기반 비선형 학습"을 담당한다.

3.3 Step 1: 데이터 준비

각 자산에 대해 다음을 수행하시오.

1. 일별 종가를 다운로드하시오.
2. 로그수익률을 계산하시오.

3. 결측치를 제거하시오.

4. 가격 시계열, 수익률 시계열, 제곱수익률 시계열을 그래프로 그리시오.

5. 평균, 표준편차, 왜도, 첨도를 계산하시오.

초보 학생들은 먼저 수익률과 제곱수익률 그래프를 보면서 다음 특징을 관찰해보면 좋다.

- 수익률은 평균 주변에서 움직이지만 큰 충격이 간헐적으로 나타나는가?
- 제곱수익률은 군집적으로 커지는 시기가 있는가?
- 특정 자산이 다른 자산보다 더 큰 변동성을 보이는가?

3.4 Step 2: AR(2)-GARCH(1,1) 모형 추정

각 자산에 대해 다음 평균방정식과 분산방정식을 추정하시오.

$$r_t = \mu + \phi_1 r_{t-1} + \phi_2 r_{t-2} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

여기서

- 평균방정식의 AR(2)는 수익률의 약한 자기상관을 설명한다.
- GARCH(1,1)는 과거 충격과 과거 분산이 현재 변동성에 미치는 영향을 반영한다.

추정 후에는 다음을 반드시 저장하시오.

- 조건부 변동성 추정치 $\hat{\sigma}_t$
- 표준화 잔차
- 1-step ahead volatility forecast

3.5 Step 3: Deep Learning 모델 설계

이제 딥러닝 모델을 사용하여 미래 변동성을 예측하시오. 기본적인 목표는 다음과 같다.

$$\widehat{RV}_{t+1} = f(X_t)$$

여기서 RV_{t+1}는 미래 realized volatility proxy이다. 일별 데이터에서는 간단하게 다음을 사용할 수 있다.

$$RV_t = r_t^2$$

딥러닝 입력변수 X_t의 예시는 다음과 같다.

- 최근 k일의 수익률
- 최근 k일의 제곱수익률
- 최근 k일의 절대수익률
- GARCH가 추정한 $\hat{\sigma}_t$

가능한 모델 예시는 다음과 같다.

- LSTM
- GRU
- Transformer

초보 학생은 LSTM 또는 GRU 중 하나만 구현해도 충분하다. 중요한 것은 "입력 시퀀스"를 구성하고, 미래 변동성을 예측하는 supervised learning 문제로 바꾸는 것이다.

3.6 Step 4: Hybrid Model 구성

Hybrid model에서는 GARCH의 조건부 변동성을 딥러닝 입력으로 추가한다. 예를 들어 다음과 같은 형태를 생각할 수 있다.

$$RV_{t+1} = f\left(r_t, r_{t-1}, \ldots, r_{t-k}, r_t^2, r_{t-1}^2, \ldots, \hat{\sigma}_t\right)$$

즉,

- GARCH만 사용하는 경우: $\hat{\sigma}_{t+1}^{GARCH}$
- DL만 사용하는 경우: $f(X_t)$
- Hybrid의 경우: $f(X_t, \hat{\sigma}_t^{GARCH})$

이때 학생들은 다음 질문을 생각해보면 좋다.

- GARCH가 제공하는 구조적 정보가 딥러닝에 실제로 도움이 되는가?
- 딥러닝이 GARCH가 설명하지 못하는 비선형 부분을 보완하는가?

3.7 Step 5: 학습/평가 구간 분할

표본을 학습 구간(train set)과 평가 구간(test set)으로 나누시오. 예를 들면 다음과 같이 나눌 수 있다.

- Train: 2018–2023
- Test: 2024–2025

모든 모형은 동일한 학습/평가 구간을 사용해야 공정한 비교가 가능하다.

3.8 Step 6: 예측 성능 평가

다음 성과지표를 사용하여 세 가지 모델을 비교하시오.

- Mean Squared Error (MSE)
- Mean Absolute Error (MAE)
- QLIKE

비교 대상은 다음과 같다.

- GARCH model
- Deep Learning model
- Hybrid GARCH + Deep Learning model

예측이 잘 되었는지 판단할 때는 단순히 숫자만 보지 말고, 예측 시계열 그래프도 함께 제시하는 것이 좋다.

3.9 Project 1에서 학생들이 제출해야 할 내용

다음을 포함한 보고서를 제출하시오.

1. 데이터 설명
2. 수익률 및 제곱수익률의 기초통계
3. AR(2)-GARCH(1,1) 추정 결과
4. 딥러닝 모델 구조 설명
5. Hybrid model 구조 설명
6. 예측 성과 비교표
7. 결과 해석

3.10 Project 1 해석 질문

다음 질문에 답하시오.

- Hybrid 모델은 왜 더 좋은 성능을 낼 수 있는가?
- 어떤 자산에서 Hybrid 효과가 가장 크게 나타났는가?
- 딥러닝이 항상 GARCH보다 우수한가?
- 금융 데이터에서 비선형성이 중요한 이유는 무엇인가?

4 Project 2 (고급): Deep Learning Enhanced Multivariate GARCH

4.1 프로젝트 목표

이 프로젝트의 목적은 다변량 금융시계열에서 자산별 변동성과 자산 간 상관관계를 동시에 분석하고, 여기에 딥러닝을 결합하는 것이다.

단일 자산 분석에서는 "변동성"만 중요했지만, 다변량 분석에서는 다음이 모두 중요하다.

- 각 자산의 개별 변동성
- 자산 간 공분산
- 자산 간 동적 상관관계

실무적으로 이는 포트폴리오 리스크관리, 헤지, VaR, 자산배분 등에 매우 중요하다.

4.2 다변량 수익률 벡터

5개 자산의 수익률을 다음과 같은 벡터로 정의하자.

$$\mathbf{r}_t = \begin{bmatrix} r_{1t} \\ r_{2t} \\ r_{3t} \\ r_{4t} \\ r_{5t} \end{bmatrix}$$

예를 들어

- r_{1t}: KOSPI
- r_{2t}: Samsung Electronics
- r_{3t}: SK Hynix
- r_{4t}: Hyundai Motor
- r_{5t}: NAVER

4.3 Step 1: 다변량 데이터셋 구성

다음을 수행하시오.

1. 5개 자산의 로그수익률을 하나의 데이터프레임으로 결합하시오.
2. 날짜를 기준으로 정렬하시오.
3. 공통 거래일만 남기고 결측치를 제거하시오.
4. 상관행렬을 계산하고 heatmap 또는 표로 제시하시오.

초보 학생은 먼저 정적 상관계수를 계산하여 어떤 자산쌍이 강하게 연결되어 있는지 확인해보면 좋다.

4.4 Step 2: VAR(2) 평균방정식 추정

다변량 평균구조를 설명하기 위해 다음 VAR(2) 모형을 추정하시오.

$$\mathbf{r}_t = \mathbf{c} + A_1\mathbf{r}_{t-1} + A_2\mathbf{r}_{t-2} + \boldsymbol{\epsilon}_t$$

여기서

- $\mathbf{c}$: 상수벡터
- A_1, A_2: 시차계수행렬
- $\boldsymbol{\epsilon}_t$: 잔차벡터

추정 후에는 다음을 해석하시오.

- 각 자산의 자기지연효과가 강한가?
- 어떤 자산의 과거 수익률이 다른 자산에 영향을 미치는가?
- 평균 spillover가 존재하는가?

4.5 Step 3: Multivariate GARCH 또는 DCC-GARCH 추정

조건부 공분산행렬을 다음과 같이 정의한다.

$$H_t = D_t R_t D_t$$

여기서

- D_t: 각 자산의 조건부 표준편차를 모은 대각행렬
- R_t: 시변 상관행렬

DCC-GARCH에서는 각 자산의 개별 분산은 univariate GARCH가 담당하고, 자산 간 상관구조는 DCC(dynamic conditional correlation)가 담당한다.

학생들은 다음을 수행하시오.

1. 각 자산의 GARCH 변동성 추정
2. DCC를 이용한 동적 상관관계 추정
3. 특정 자산쌍의 상관관계 시계열 시각화

예를 들어 다음 자산쌍을 분석할 수 있다.

- KOSPI – Samsung Electronics
- Samsung Electronics – SK Hynix
- Hyundai Motor – NAVER

4.6 Step 4: Deep Learning Enhanced MGARCH

이제 딥러닝을 사용하여 다변량 GARCH 구조를 확장하시오. 가능한 접근 방법은 다양하다.

- 각 자산의 volatility를 LSTM으로 예측
- 상관행렬 요소를 딥러닝으로 예측
- covariance matrix dynamics를 neural network로 근사
- DCC 구조의 일부를 neural network로 대체

초보 학생에게는 다음과 같은 단순화된 접근도 허용할 수 있다.

- 각 자산에 대해 LSTM volatility forecast 수행
- 자산쌍별 rolling correlation을 딥러닝으로 예측
- 이를 전통적 DCC 결과와 비교

조금 더 고급 수준의 학생은 다음과 같은 아이디어를 시도할 수 있다.

- 입력: 최근 k일 수익률 벡터
- 출력: 다음 시점의 covariance matrix 또는 selected pairwise correlations

4.7 Step 5: 비교 기준

다음 두 계열을 비교하시오.

- 전통적 모형: VAR + DCC-GARCH
- 딥러닝 확장 모형: Deep Learning Enhanced MGARCH

비교 대상은 다음과 같다.

- volatility forecasting accuracy
- correlation forecasting accuracy
- market stress period에서의 설명력
- 해석 가능성

4.8 Step 6: 경제적 해석

학생들은 단순히 숫자만 제시하지 말고 다음을 논의하시오.

- 시장 충격 시 자산 간 상관관계는 상승하는가?
- 반도체 관련 종목 간 연동성이 특히 강한가?
- 동적 상관관계 추정이 왜 포트폴리오 위험관리에서 중요한가?
- 딥러닝을 추가했을 때 어떤 정보가 더 포착되는가?

4.9 Project 2에서 학생들이 제출해야 할 내용

다음을 포함한 보고서를 제출하시오.

1. 다변량 데이터 설명
2. 정적 상관행렬 및 기초분석
3. VAR(2) 추정 결과
4. DCC-GARCH 또는 MGARCH 추정 결과
5. 딥러닝 확장 모형 설명
6. volatility/correlation 예측 성과 비교
7. 경제적 해석

5 제출물 안내

두 프로젝트 모두 다음을 제출하시오.

- 보고서(PDF)
- Python 코드
- 결과표
- 그래프

보고서는 다음 구조를 권장한다.

1. Introduction
2. Data
3. Methodology
4. Empirical Results
5. Discussion
6. Conclusion

6 채점 기준

평가 항목	점수
데이터 수집 및 전처리	20
모형 구현의 정확성	30
예측 평가 및 비교분석	25
경제적 해석 및 보고서 완성도	25

7 초보 학생을 위한 조언

이 프로젝트는 처음에는 복잡해 보일 수 있지만, 다음 순서대로 진행하면 훨씬 수월하다.

1. 먼저 가격 데이터를 다운로드한다.
2. 로그수익률을 계산한다.
3. 수익률과 제곱수익률 그래프를 그린다.
4. GARCH 모형을 하나 먼저 추정한다.
5. 그 다음 딥러닝 입력데이터를 만든다.
6. 마지막으로 예측 성과를 비교한다.

특히 Project 2는 난도가 높으므로, 먼저 Project 1을 충분히 이해한 뒤 진행하는 것이 좋다. 코드 구현에서 완벽한 복잡성을 추구하기보다, **모형의 아이디어를 정확히 이해하고 비교하는 것**이 더 중요하다.

8 마무리

이 프로젝트를 통해 학생들은 금융시계열 분석의 핵심인 변동성 예측 문제를 전통적 계량모형과 현대적 딥러닝 모형의 관점에서 모두 경험하게 된다. 또한 단일 자산에서 시작해 다변량 상관구조까지 확장함으로써, 실제 금융 리스크관리와 자산배분 문제에 가까운 분석을 수행할 수 있다.