금융기계학습 실습과제

Pair Trading Strategy on KOSPI Top 50 Stocks

1 과제 개요

본 과제의 목적은 코스피 시장 내 시가총액 상위 50개 종목을 대상으로 pair trading 전략을 설계하고, 실제 투자전략 관점에서 성과를 평가하는 것이다.

학생들은 다음의 전체 과정을 수행한다.

1. 투자 대상 종목군 구성
2. 주가 데이터 수집 및 전처리
3. 유사한 pair 후보 탐색
4. 최종 3개 pair 선정
5. 훈련기간에서 spread 및 거래규칙 학습
6. 검증기간에서 거래규칙 조정
7. 테스트기간에서 out-of-sample 투자성과 평가

본 과제에서 중요한 것은 단순히 높은 수익률을 얻는 것이 아니다. 오히려 중요한 것은 다음과 같다.

- 미래 정보를 사용하지 않는 엄밀한 실험 설계
- pair 선정 논리의 타당성
- 거래규칙의 명확성
- 테스트 기간에서의 객관적 성과평가
- 전략이 성공하거나 실패한 이유에 대한 해석

2 투자 대상 Universe

투자 대상은 다음과 같다.

현재 시점 기준 코스피 시장 내 시가총액 상위 50개 종목

단, 현재 시점의 시가총액 상위 종목을 사용하는 경우 survivorship bias가 발생할 수 있다. 즉, 현재까지 살아남고 성장한 기업만 포함될 가능성이 있다.

본 과제에서는 교육 목적상 현재 시점의 top 50 종목 사용을 허용한다. 다만 최종 보고서의 limitation section에서 반드시 이 문제를 언급해야 한다.

3 데이터 수집

3.1 자료 출처

주가 데이터는 다음 출처 중 하나를 사용할 수 있다.

- Yahoo Finance
- FinanceDataReader
- KRX 또는 기타 공신력 있는 금융 데이터 소스

Python에서는 예를 들어 다음과 같은 패키지를 사용할 수 있다.

- `yfinance`
- `FinanceDataReader`
- `pandas`
- `numpy`
- `statsmodels`

3.2 데이터 기간

전체 데이터 기간은 다음과 같이 설정한다.

2010년 이후부터 최근까지의 일별 주가 데이터

가능하면 수정주가(adjusted close)를 사용할 것을 권장한다. 수정주가는 배당, 액면분할 등의 영향을 반영하므로 장기 분석에 더 적합하다.

4 Train / Validation / Test 기간 설정

Pair trading은 거래 신호가 자주 발생하지 않을 수 있다. 따라서 테스트 기간이 너무 짧으면 성과 평가의 신뢰성이 낮다.

권장 기간 설정은 다음과 같다.

구분	예시 기간	목적
Training period	2010–2018	Pair 선정, spread 구조 추정
Validation period	2019–2021	거래규칙 및 threshold 조정
Test period	2022–최근	최종 out-of-sample 성과평가

중요한 원칙은 다음과 같다.

Test period의 정보는 pair 선정, parameter tuning, model training에 절대 사용하면 안 된다.

5 Pair Trading의 기본 아이디어

Pair trading은 두 종목의 가격 관계가 장기적으로 안정적이라고 가정하고, 일시적으로 가격 차이가 벌어졌을 때 다시 평균으로 회귀할 것을 기대하는 전략이다.

예를 들어 두 종목의 가격을 각각 $P_{1,t}$, $P_{2,t}$라고 하자. 두 종목이 장기적으로 유사하게 움직인다면 다음과 같은 관계를 생각할 수 있다.

$$P_{1,t} = \alpha + \beta P_{2,t} + \epsilon_t$$

여기서 ϵ_t는 두 종목 간 가격 괴리, 즉 spread로 해석할 수 있다.

$$Spread_t = P_{1,t} - \beta P_{2,t}$$

Pair trading의 핵심은 다음과 같다.

- spread가 비정상적으로 커지면 다시 줄어들 가능성이 있다.
- spread가 비정상적으로 작아지면 다시 커질 가능성이 있다.
- 따라서 spread의 평균회귀(mean reversion)를 이용해 long-short 포지션을 구성한다.

6 Pair Selection: 좋은 Pair 찾기

코스피 top 50 종목에서 가능한 pair의 수는 다음과 같다.

$$\binom{50}{2} = 1225$$

즉, 총 1225개의 후보 pair 중에서 투자에 적합한 pair를 찾아야 한다.

6.1 주의사항: Pair 선정은 Training Period만 사용

가장 중요한 원칙은 다음과 같다.

Pair selection은 반드시 training period의 데이터만 사용해야 한다.

예를 들어 2010–2018년을 training period로 설정했다면, 2019년 이후의 데이터는 pair 선정에 사용하면 안 된다.

전체 기간을 보고 가장 성과가 좋은 pair를 고른 뒤 test period 성과를 평가하는 것은 look-ahead bias에 해당한다.

7 Pair Selection 방법

학생들은 최소 2개 이상의 pair selection 방법을 비교해야 한다.

7.1 방법 1: Correlation

가장 단순한 방법은 두 종목 수익률 간 상관계수를 계산하는 것이다.

$$\rho_{ij} = Corr(r_{i,t}, r_{j,t})$$

상관계수가 높은 두 종목은 유사한 가격 움직임을 보일 가능성이 있다.
하지만 주의해야 한다.

높은 correlation이 곧 좋은 pair trading 기회를 의미하지는 않는다.

두 종목이 함께 상승하거나 함께 하락하면 correlation은 높을 수 있다. 그러나 spread가 평균회귀하지 않는다면 pair trading에는 적합하지 않을 수 있다.

7.2 방법 2: Cointegration

Pair trading에서 더 중요한 개념은 cointegration이다.

두 가격 시계열이 각각 비정상적(non-stationary)이더라도, 특정 선형결합이 정상적(stationary)이라면 두 종목은 장기 균형관계를 가진다고 볼 수 있다.

$$P_{1,t} = \alpha + \beta P_{2,t} + \epsilon_t$$

여기서 잔차 ϵ_t가 stationary하다면, 두 종목의 spread가 평균회귀한다고 해석할 수 있다.

Python에서는 다음 함수를 사용할 수 있다.

```
statsmodels.tsa.stattools.coint
```

일반적으로 cointegration test의 p-value가 낮을수록 pair trading 후보로 적합하다고 볼 수 있다.

7.3 방법 3: Distance Method

Normalized price를 이용하여 두 종목의 가격 경로가 얼마나 유사한지 계산할 수 있다.

$$P^*_{i,t} = \frac{P_{i,t}}{P_{i,0}}$$

두 종목 i, j의 distance는 다음과 같이 계산할 수 있다.

$$D_{ij} = \sum_{t=1}^{T} \left(P^*_{i,t} - P^*_{j,t} \right)^2$$

D_{ij}가 작을수록 두 종목의 가격 경로가 유사하다고 볼 수 있다.

7.4 방법 4: DTW 또는 Machine Learning 기반 유사도

고급 선택 사항으로 Dynamic Time Warping(DTW), clustering, PCA 등을 사용할 수 있다.

다만 고급 방법을 사용할 경우에도 반드시 다음을 설명해야 한다.

- 왜 해당 방법을 사용했는가?
- 기존 correlation 또는 cointegration 방식보다 어떤 장점이 있는가?
- 과최적화 위험은 없는가?

8 최종 Pair 선정

각 팀은 최종적으로 3개 pair를 선정해야 한다.

1개 pair만 선택하면 특정 종목의 우연한 움직임에 결과가 크게 좌우될 수 있다. 3개 pair를 사용하면 전략의 분산효과를 어느 정도 기대할 수 있다.

최종 pair 선정 기준은 예를 들어 다음과 같이 구성할 수 있다.

- 높은 correlation
- 낮은 cointegration p-value
- 짧지만 지나치게 짧지 않은 half-life
- 경제적 또는 산업적 유사성
- 충분한 거래량과 유동성

9 Spread와 Z-score 계산

선정된 pair에 대해 spread를 계산한다.

$$Spread_t = P_{1,t} - \beta P_{2,t}$$

여기서 β는 hedge ratio로 해석할 수 있다. 일반적으로 training period에서 OLS 회귀분석을 통해 추정한다.

$$P_{1,t} = \alpha + \beta P_{2,t} + \epsilon_t$$

그 다음 spread의 z-score를 계산한다.

$$z_t = \frac{Spread_t - \mu_t}{\sigma_t}$$

여기서 μ_t와 σ_t는 rolling window를 이용해 계산할 수 있다.
예를 들어 60일 rolling window를 사용하면,

$$\mu_t = \text{RollingMean}_{60}(Spread_t)$$

$$\sigma_t = \text{RollingStd}_{60}(Spread_t)$$

10 Trading Rule 설계

기본적인 z-score 기반 trading rule은 다음과 같다.

10.1 진입 규칙

- $z_t > k$이면 spread가 과도하게 커졌다고 판단한다.
- 이 경우 spread가 축소될 것으로 기대하고 short spread 포지션을 취한다.
- $z_t < -k$이면 spread가 과도하게 작아졌다고 판단한다.
- 이 경우 spread가 확대될 것으로 기대하고 long spread 포지션을 취한다.

예를 들어 $k = 2$로 설정할 수 있다.

10.2 청산 규칙

다음 중 하나 이상의 청산 규칙을 설정한다.

- $|z_t| < 0.5$이면 청산
- z_t가 0에 도달하면 청산
- 손실이 일정 수준을 넘으면 stop-loss
- 최대 보유기간을 초과하면 강제 청산

Parameter	예시 값	설명
Entry threshold	1.5, 2.0, 2.5	진입 기준 z-score
Exit threshold	0, 0.5, 1.0	청산 기준 z-score
Rolling window	40, 60, 90일	평균과 표준편차 계산 기간
Stop-loss	5%, 10%, 15%	손실 제한
Max holding period	20, 40, 60일	최대 보유기간

11 Validation Period에서 조정할 수 있는 항목

Validation period에서는 다음 parameter를 조정할 수 있다.

단, parameter를 지나치게 세밀하게 조정하면 overfitting이 발생할 수 있다.

예를 들어 다음과 같은 방식은 바람직하지 않다.

$$Entry = 2.13, \quad Exit = 0.37, \quad StopLoss = 7.42\%$$

대신 제한된 grid search를 사용하는 것이 좋다.

12 Test Period에서의 원칙

Test period에서는 모든 것을 고정해야 한다.

- Pair 변경 금지
- Hedge ratio 재추정 금지 또는 사전에 정한 방식만 허용
- Entry/exit threshold 변경 금지
- Stop-loss 변경 금지
- Rolling window 변경 금지

즉, test period는 완전히 새로운 데이터에 대해 전략이 실제로 작동하는지 평가하는 구간이다.

13 포지션 구성

Pair trading은 일반적으로 long-short 전략이다.

예를 들어 spread가 다음과 같이 정의되어 있다고 하자.

$$Spread_t = P_{1,t} - \beta P_{2,t}$$

13.1 Long Spread

$z_t < -k$이면 spread가 너무 작다고 판단한다. 따라서 spread가 다시 커질 것을 기대한다.

$$\text{Long Spread} = \text{Long Stock 1} + \text{Short Stock 2}$$

13.2 Short Spread

$z_t > k$이면 spread가 너무 크다고 판단한다. 따라서 spread가 다시 줄어들 것을 기대한다.

$$\text{Short Spread} = \text{Short Stock 1} + \text{Long Stock 2}$$

14 거래비용과 공매도 가정

본 과제에서는 공매도가 가능하다고 가정한다. 다만 현실에서는 공매도 제약, 대차비용, 유동성 제약이 존재한다.

따라서 보고서에서 반드시 다음 가정을 명시해야 한다.

- 공매도 가능 여부
- 거래비용
- 슬리피지 반영 여부
- 유동성 제약 고려 여부

최소한 거래비용은 반드시 반영해야 한다.
예를 들어 다음과 같이 설정할 수 있다.

$$\text{Transaction Cost} = 0.15\% \quad \text{per trade}$$

또는 round-trip 기준으로,

$$\text{Round-trip Cost} = 0.30\%$$

거래비용을 반영하지 않은 전략은 실제 투자전략으로 해석하기 어렵다.

15 성과평가 지표

Test period에서 다음 지표를 반드시 계산해야 한다.

15.1 누적수익률

$$R_{cum} = \prod_{t=1}^{T}(1 + r_t) - 1$$

15.2 연율화 수익률

$$R_{ann} = (1 + R_{cum})^{252/T} - 1$$

여기서 T는 test period의 거래일 수이다.

15.3 연율화 변동성

$$\sigma_{ann} = \sigma_d\sqrt{252}$$

여기서 σ_d는 일별 수익률의 표준편차이다.

15.4 Sharpe Ratio

$$Sharpe = \frac{R_{ann} - R_f}{\sigma_{ann}}$$

단순화를 위해 무위험수익률 R_f는 0으로 가정해도 된다. 무위험수익률을 사용하는 경우 그 출처를 명시해야 한다.

15.5 Maximum Drawdown

누적자산가치를 V_t라고 하자. 이때 시점 t까지의 최고값은 다음과 같다.

$$Peak_t = \max_{\tau \le t} V_\tau$$

Drawdown은 다음과 같다.

$$DD_t = \frac{V_t - Peak_t}{Peak_t}$$

Maximum drawdown은 다음과 같다.

$$MDD = \min_t DD_t$$

15.6 Win Rate

$$WinRate = \frac{\#\text{Winning Trades}}{\#\text{Total Trades}}$$

15.7 Profit Factor

$$ProfitFactor = \frac{\text{Gross Profit}}{|\text{Gross Loss}|}$$

15.8 거래 횟수

거래 횟수는 반드시 보고해야 한다.

거래 횟수가 너무 적으면 Sharpe ratio나 누적수익률이 높더라도 통계적으로 신뢰하기 어렵다.

예를 들어 test period에서 거래가 3회뿐이라면, 그 성과는 전략의 우수성보다 우연에 의해 발생했을 가능성이 크다.

16 Benchmark 비교

전략 성과는 반드시 benchmark와 비교해야 한다.

가능한 benchmark는 다음과 같다.

- KOSPI index buy-and-hold
- 동일 종목군 equal-weight portfolio
- 단순 z-score pair trading 전략
- Machine learning을 사용하지 않은 baseline 전략

특히 machine learning 방법을 사용한 경우, 반드시 ML을 사용하지 않은 baseline과 비교해야 한다.

17 Hyperparameter Tuning에 대한 안내

본 과제에서는 pair trading 전략의 성과를 개선하기 위해 일부 hyperparameter를 조정(tuning)할 수 있다.

다만, 다음 원칙을 반드시 준수해야 한다.

Hyperparameter tuning은 validation period에서만 수행해야 한다.

즉, test period의 성과를 보고 parameter를 수정하는 것은 허용되지 않는다. 이는 미래 정보를 사용한 **look-ahead bias** 또는 **data snooping**에 해당한다.

17.1 가능한 Hyperparameter 예시

학생들은 다음 parameter를 조정할 수 있다.

Hyperparameter	예시 값	설명
Entry threshold	1.5, 2.0, 2.5	진입 기준 z-score
Exit threshold	0, 0.5, 1.0	청산 기준 z-score
Rolling window	40, 60, 90일	z-score 계산 window
Stop-loss	5%, 10%, 15%	손실 제한
Take-profit	optional	이익 실현 기준
Max holding period	20, 40, 60일	최대 보유기간
Pair selection score	optional	pair ranking 방식

Machine Learning 모델을 사용하는 경우, 모델의 hyperparameter tuning도 validation period에서만 수행해야 한다.

예를 들어 다음과 같은 hyperparameter를 조정할 수 있다.

- Logistic Regression: regularization strength
- Random Forest: number of trees, max depth
- XGBoost: learning rate, max depth, subsample
- LSTM/GRU: hidden dimension, sequence length, learning rate

17.2 과도한 Parameter Tuning 주의

지나치게 세밀한 parameter tuning은 과최적화(overfitting)를 유발할 수 있다.

예를 들어 다음과 같은 parameter 선택은 권장하지 않는다.

$$Entry = 2.13, \quad Exit = 0.37, \quad StopLoss = 7.42\%$$

대신 다음과 같이 제한된 범위의 grid search를 권장한다.

$$Entry \in \{1.5, 2.0, 2.5\}$$

$$Exit \in \{0, 0.5, 1.0\}$$

즉,

> **좋은 전략은 복잡한 parameter tuning이 아니라, out-of-sample에서 robust하게 작동하는 전략이다.**

최종 제출물에는 다음 내용을 반드시 포함해야 한다.

- 어떤 hyperparameter를 tuning했는가?
- tuning 범위를 어떻게 설정했는가?
- 최종 parameter를 왜 선택했는가?
- validation period 성과와 test period 성과가 어떻게 달랐는가?

18 보고서에 반드시 포함할 내용

최종 보고서는 다음 항목을 포함해야 한다.

1. 연구 목적
2. 데이터 설명
3. Universe 구성 방식
4. Train / validation / test 기간 설정
5. Pair selection 방법
6. 최종 3개 pair 선정 이유
7. Spread 및 hedge ratio 계산 방식
8. Trading rule
9. 거래비용 및 공매도 가정
10. Test period 성과평가
11. Benchmark 비교
12. Equity curve
13. Drawdown curve
14. 전략의 한계
15. 향후 개선 방향

19 필수 그림

보고서에는 다음 그림을 포함해야 한다.

- 최종 선정된 pair의 normalized price plot
- Spread plot
- Z-score plot
- Trading signal plot
- Strategy cumulative return
- Benchmark cumulative return
- Drawdown curve

20 주의해야 할 대표적 실수

20.1 전체 기간으로 pair를 고르는 경우

전체 기간 데이터를 보고 pair를 선정한 뒤 test period 성과를 계산하면 미래 정보를 사용한 것이다.
이는 look-ahead bias에 해당한다.

20.2 Correlation만 보고 pair를 고르는 경우

Correlation이 높아도 spread가 평균회귀하지 않을 수 있다.
따라서 cointegration, stationarity, spread behavior를 함께 확인해야 한다.

20.3 거래비용을 무시하는 경우

거래비용을 반영하지 않은 전략은 실제 투자전략으로 보기 어렵다.

20.4 거래 횟수가 너무 적은 경우

거래가 몇 번 발생하지 않았는데 높은 수익률을 보였다면, 이는 전략의 우수성보다 우연일 수 있다.

20.5 Test period에서 parameter를 수정하는 경우

Test period 성과를 보면서 threshold를 수정하면 안 된다. 이는 out-of-sample test가 아니라 data snooping이다.

21 평가 기준

항목	비중
데이터 수집 및 전처리	15%
Pair selection 방법의 타당성	20%
Train / validation / test 설계	20%
Trading rule 및 backtest 구현	20%
성과평가 및 해석	15%
보고서 완성도 및 재현 가능성	10%

22 중요한 평가 원칙

본 과제에서 높은 수익률 자체가 높은 점수를 보장하지 않는다.
다음과 같은 경우 높은 평가를 받을 수 있다.

- 수익률은 낮더라도 실험 설계가 엄밀한 경우
- 전략 실패 원인을 설득력 있게 분석한 경우
- look-ahead bias를 철저히 통제한 경우
- 거래비용과 위험을 현실적으로 반영한 경우
- benchmark 대비 전략의 장단점을 명확히 해석한 경우

반대로 다음과 같은 경우 감점될 수 있다.

- Test data를 pair selection에 사용한 경우
- 거래비용을 반영하지 않은 경우
- 성과지표를 수익률만 제시한 경우
- 코드가 재현되지 않는 경우
- 전략의 경제적 rationale이 없는 경우

23 제출물 및 제출기한

제출물은 다음과 같다.

1. **Python Codes**
2. **최종 보고서 PPT (20쪽 이내)**
3. **Dataset (CSV format)**

코드는 반드시 재현 가능해야 한다. 즉, 데이터 다운로드부터 성과평가까지 한 번에 실행될 수 있도록 작성해야 한다.

제출 기한

- 2026.5.26 화요일 23:59